

研究目标：建模真实网络流量的非平稳特性、提升预测准确度

研究内容1：网络流量非平稳性分析

$$P(x_{t_1 + \tau}, \dots, x_{t_k + \tau}) \neq P(x_{t_1}, \dots, x_{t_k}), \quad \forall \tau$$

$$P(x_{t_1}, \dots, x_{t_m}) \neq P(x_{t_{m+1}}, \dots, x_{t_{m+n}})$$

$$P(x_t, \dots) = P(x_{t+\tau}, \dots)$$

$$P(x_{t_1}, y_{t_2}, \dots) \neq P(x_{t_1 + \tau}, y_{t_2 + \tau}, \dots)$$

$$P(x_t, \dots) = P(x_{t+\tau}, \dots)$$

$$P(y_t, \dots) = P(y_{t+\tau}, \dots)$$

$$P(X_t, Y_t, \dots) \neq P(X_{t+\tau}, Y_{t+\tau}, \dots)$$

$$P(X_t, \dots) = P(X_{t+\tau}, \dots)$$

$$P(Y_t, \dots) = P(Y_{t+\tau}, \dots)$$

$$P(x'_{t_1}, \dots, x'_{t_m}) \neq P(x'_{t_{m+1}}, \dots, x'_{t_{m+n}})$$

$$P(x'_{t_1}, \dots, x'_{t_m} | E_1) = P(x'_{t_{m+1}}, \dots, x'_{t_{m+n}} | E_1)$$

$$P(x'_{t_1}, \dots, x'_{t_m} | E_2) = P(x'_{t_{m+1}}, \dots, x'_{t_{m+n}} | E_2)$$

移动网络流量的高阶矩分布偏移

视频流量的长程依赖

学术网络流量的多尺度依赖

卫星网络流量的事件驱动分布偏移

研究内容4

高阶矩交互预测模型

- 高阶矩归一化运算：扩展均值、方差标准化，提出高阶矩标准化
- 库普曼算子：统计矩动态非线性演化映射到线性空间
- 统计矩交互注意力机制：多头注意力建模高阶矩相关性

使用后将骨干模型的预测误差平均降低 20%

↑ 支撑

研究内容2

自注意力序列预测模型

- 编码器 + 解码器架构、多头自注意力机制：建模多时间序列间长程依赖
- 视频帧位置编码：视频类别信息显示编码到视频流量序列
- "教师强制"训练策略：训练阶段提示预测，缓解误差累积

相比标准 Transformer 平均误差损失降低 9.7%

↑ 支撑

研究内容3

自适应时钟神经网络模型

- 时钟 LSTM：将 LSTM 隐藏状态拆为 k 个不同频率子单元，捕捉不同尺度的流量特征
- 自适应采样间隔：对输入流量序列进行滑动自相关分析，选取 k 个最高自相关系数对应的时延作为采样间隔

相比 LSTM 的精度平均提升 23% 且推理时间较 Transformer 减少 65%

↑ 支撑

研究内容5

事件感知非平稳预测模型

- 自回归扩散模型：概率生成方式建模网络流量不确定性
- 条件注意力机制：时序分类器自由机制建模事件对网络流量的影响
- 事件感知时间步：不同事件下时间序列建模难度不同

概率预测精度平均提升 41.3% 确定性预测精度平均提升 27.5%

↑ 支撑

最终任务：为网络规划、流量调度等智能网络管理与自智网络应用提供理论支撑与技术基础